Veri Setleri ve Grafikler

Beste Ünal

20.11.2022

ÖZET

3 farklı veri seti verilmiştir. Bu veri setlerinin her birinde 3 durum ele alınmış ve uygun grafikler seçilerek grafiklendirilmiştir. Okunurluğu ve anlaşılırlığını arttırmak için estetikleri ile oynanmıştır. Grafiklerin her biri yorumlanmış ve kodları paylaşılmıştır.

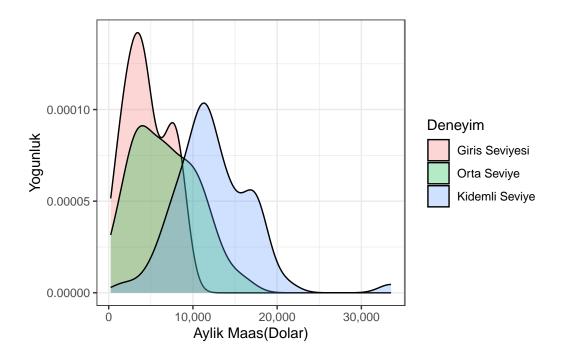
Grafikleri çizdirebilmek için gerekli paketler ve kütüphaneler yüklenmiştir.

```
options(repos = list(CRAN = "http://cran.rstudio.com/"))
install.packages("ggplot2")
library(ggplot2)
install.packages("tidyverse")
library(tidyverse)
install.packages("dplyr")
library(dplyr)
install.packages("gridExtra")
library(gridExtra)
install.packages("latexpdf")
library(latexpdf)
install.packages("MetBrewer")
library(MetBrewer)
```

1 VERİ BİLİMCİ MAAŞLARI

1.1 Tecrübe Düzeyine Göre Veri Bilimi Pozisyonları Aylık Maaşların Dolar Karşılığı Bazından Dağılımı Grafiği

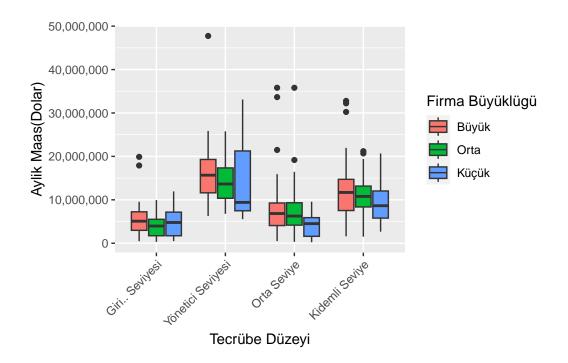
```
data5 <- read csv("Data Science Fields Salary Categorization.csv")
New names:
Rows: 607 Columns: 10
-- Column specification
----- Delimiter: "," chr
(6): Designation, Experience, Employment_Status, Employee_Location, Comp... dbl
(3): ...1, Working_Year, Remote_Working_Ratio num (1): Salary_In_Rupees
i Use `spec()` to retrieve the full column specification for this data. i
Specify the column types or set `show_col_types = FALSE` to quiet this message.
* `` -> `...1`
  data1.1 <- filter(data5, Designation == 'Data Scientist'|</pre>
                     Designation == 'Director Of Data Science'|
                     Designation == 'Head Of Data Science'|
                     Designation == 'Principal Data')
  ggplot(data1.1, aes(x = Salary_In_Rupees/978, fill = Experience )) +
    geom_density(alpha = 0.3) +
    scale_x_continuous(labels = scales::comma) +
    scale_y_continuous(labels = scales::comma) +
    scale_fill_discrete(labels = c("Giris Seviyesi", "Orta Seviye", "Kidemli Seviye")) +
  labs(x = "Aylik Maas(Dolar)", y = "Yogunluk",
         fill = "Deneyim") +
    theme bw()
```



YORUM: Giriş seviyesindeki çalışanların aldıkları maaşların yoğunlukları diğer çalışanlara göre daha fazladır. Orta seviyedeki çalışanların maaşları 20.000.00 doları geçmemektedir Kıdemli seviyesinde çalışanların maaş yoğunluğu 10.000-15.000dolar arasındadır denilebilir.

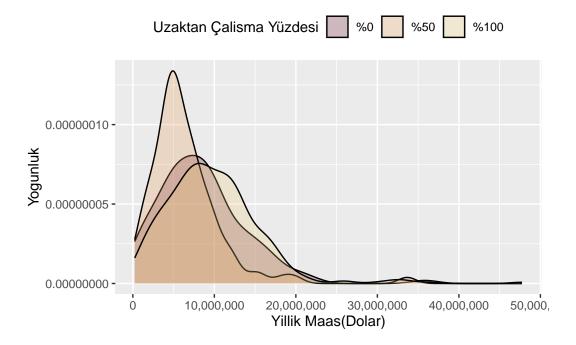
1.2 Firma Büyüklüğüne Ve Tecrübe Düzeyine Göre Aylık Maaş Tutarı Dağılımı Grafiği

```
data5 <- data5 %>%
    group_by(Experience)
ggplot(data5, aes(x = Experience, y = Salary_In_Rupees, fill = Company_Size)) +
    geom_boxplot() +
    scale_y_continuous(labels = scales::comma) +
    labs(x = "Tecrübe Düzeyi", y = "Aylik Maas(Dolar)",
        fill = "Firma Büyüklügü" ) +
    scale_fill_discrete(labels = c("Büyük", "Orta", "Küçük")) +
    scale_x_discrete(labels = c("Giriş Seviyesi", "Yönetici Seviyesi", "Orta Seviye",
    "Kidemli Seviye")) +
    theme(axis.text.x = element_text(angle = 45, vjust = 1, hjust = 1))
```



YORUM: Firma büyüklüğünün artması ile tecrübe düzeylerine göre aylık maaş artış miktarı en fazla olan Yönetici Seviyesindeki kişiler iken,artışı en az olan ise Giriş Seviyesinde çalışanlardır.. Yönetici seviyesindeki kişilerin çalıştığı firma büyüklüğü arttıkça aldıkları maaşta artmaktadır.Bu durum kıdemli seviyesindeki çalışanlar içinde geçerlidir.

1.3 Uzaktan Çalışma Maaş Yüzdesi Sistemine Göre Yıllık Maaş Ücreti Dağılım Grafiği



YORUM: Uzaktan çalışma yüzdesinin %50 olduğu durumda yıllık maaş ücreti yoğunluğu 10.000 dolardan azdır. Uzaktan çalışma yüzdesinin %0 ve %100 olduğu durumlardaki aldıkları yıllık maaş birbirlerine çok yakındır. Bu şirkette çalışan kişilerin uzaktan çalışma yüzdesinin %50 olduğu durumda daha fazla insan çalıştığını söyleyebiliriz.

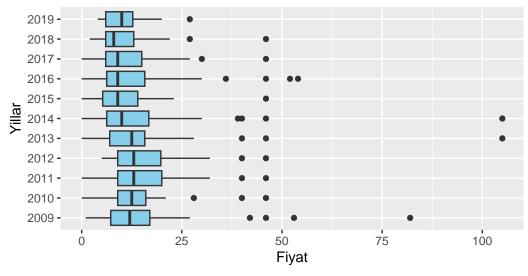
2 EN ÇOK SATAN KİTAPLAR

2.1 Yıllara Göre En Çok Satan Kitap Fiyatları Grafiği

Verilen veri setinden alınan Yıllar(Year) ve Fiyat(Price) değişkenlerine göre "Yıllara Göre En Çok Satan Kitap Fiyatları" kutu grafiği çizdirildi. Estetikleri ile oynanıp okunurluğu ve anlaşırlığı düzeltildi.

Yillara Göre En Çok Satan Kitap Fiyatlari

Kutu Grafigi



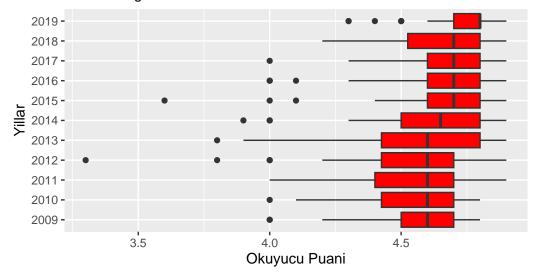
YORUM: Kitap fiyarlarının en ucuz olduğu yıl 2018 yılıdır. 2013 ve 2014 yıllarındaki kitap fiyatlarında 2 kitap fiyatı 100 TL'yi geçmiştir. Kitap fiyatlarında 0-25 TL fiyat aralığı dışında 25-50 TL fiyat aralığında da olan bir çok kitap mevcuttur.

2.2 Yıllara Göre En Çok Satan Kitapların Aldıkları Okuyucu Puanları Grafiği

Verilen veri setinden alınan Yıl(Year) ve Okuyucu Puanı(Reviews) değişkenleri kullanılarak "Yıllara Göre En Çok Satan Kitapların Aldıkları Okuyucu Puanları" kutu grafiği çizdirildi. Okunurluğunun ve anlaşırlığının artması için estetiklerele zenginleştirildi. ["Year" değişkeninin sınıfı numaric olduğu için as.factor() kullanılarak factor yapıldı.]

Yillara Göre En Çok Satan Kitaplarin Aldiklari Okuyucu Puanlari

Kutu Grafigi



Yorum: Okuyucuların Kitaplara verdiği en yüksek puanlar 2019 yılındadır. En çok okunan kitaplara okuyucular tarafınfan verilen puanların değişimi en yüksek 2013 yılındadır ve en düşük 2019 yılındadır. Yıllar geçtikçe kitap okuma oranlarının yükseldiğini söyleyebiliriz çünkü okuyucuların verdiği puanlarda artmaktadır.

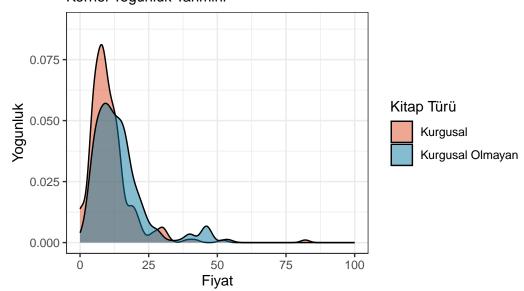
2.3 Türürne Göre Kitap Fiyatlarının Dağılımı Grafiği

Data2 veri seti "Data2.1" ismine atanmıştır. Veri setindeki NA değerleri çıkartılmıştır. Sonra Genre değişkenindeki "Fiction" ve "Non Ficiton" çıktıları alınarak Yıl(Year) ile gruplandırılmıştır. Ve Fiyatlar(Price) özetlenmiştir. Bunların hepsi Data2.1 içerisine atılmıştır.

```
Data2.1 <- Data2 %>%
  drop_na() %>%
  filter( Genre %in% c("Fiction", "Non Fiction")) %>%
  group_by(Year,Genre) %>%
  summarise(Price)
```

Oluşturulan yeni Data2 veri setinden Fiyat(Price) ve Kitap Türü(Genre)değişkenleri kullanılarak bir yoğunluk grafiği çizdirildi. Estekikleri düzeltildi ve böylece okunurluğu arttırılmıştır.

Türüne Göre Kitap Fiyatlarinin Dagilimi Kernel Yogunluk Tahmini



Yorum: Kurgusal Kitap türleri 0-25 TL fiyat aralığında daha çok tercih edilmiştir. Kurgusal olmayan Kitap Türleri 25-50 TL fiyat aralığında Kurgusal Kitap Türlerinden daha çok tercih edilmiştir.

3 TV DIZILERI

Veri seti "Data3" olarak yeniden adlandırılmıştır. Data2 veri setindeki "original title" değişkeni original_title olarak yeniden adlandırılmıştır. Data2 veri setindeki "number of seasons" değişkeni number of seasons olarak yeniden adlandırılmıştır.

```
turkish_tvseries <- read_csv("turkish_tvseries.csv")
library(readr)
DataTv <- read_csv("DataTv.csv")
colnames(DataTv)[2] <- c("number_of_seasons")</pre>
```

3.1 Dizi Sürelerinin Dağılımı Grafiği

NA değerleri çıkartılarak Dizilerin Sezon Sayıları(Number Of Season) ve Dizi Süreleri(runtimes) yeni bir excel dosyası(DataTv) haline getirilmiştir. R'a yüklenmiştir ve tanımlanmıştır. Daha sonra DataTv veri setinde bulunan Dizi Süreleri(runtimes) değişkeni kullanılarak Dizi Sürelerinin Dağılımı Grafiğini gösteren bir kutu grafiği çizilmiştir.

Dizi Sürelerinin Dagilimi Histogram 200 200 200 Dizi Sürelerinin Dagilimi Histogram 200 200 200 200 200 200 250 Dizi Süreleri

YORUM: Yukarıda verilen grafikte dizi sürelerinin yoğun olduğu aralık 0-1000 dakika arasıdır. 1000 dakikadan fazla süren dizi yoğunluğu azalmaktadır.

3.2 Dizi Sürelerinin 2000 Yılı Öncesi Ve Sonrası Dağılımı Grafiği

turkish_tvseries.year veri setinden yıl(Year) değişkeni alınmış ve dizi ye atanarak yeniden veri seti oluşturulmuştur. turkish_tvseries.year verisetinde bulunan yıl(Year) değişkeni 2000 yılından önce ve sonra şeklinde ayrılarak grup(group) değişkenine atanmıştır. turkish_tvseries.year verisetinde bulunan Dizilerin Süresi(runtimes) değişkeni ve dizi değişkeni alınıp yeni bir dizi2 veri seti oluşturulmuştur.

```
library(readxl)
dizi <- data.frame(turkish_tvseries$year)

dizi$group <- as.factor(ifelse(dizi$turkish_tvseries.year < 2000, "2000 yılından önce", "2

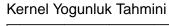
dizi2 <- data.frame(turkish_tvseries$runtimes, dizi)

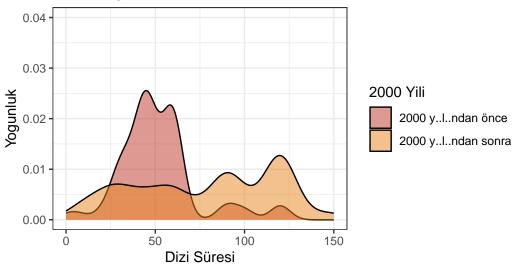
dizi2 <- dizi2[-c(302, 327, 415, 585, 676, 735, 827, 1018, 1166, 1167, 1238, 1271, 1346, 1]

dizi2 = dizi2[complete.cases(dizi2), ]</pre>
```

```
ggplot(dizi2, aes(group =dizi2$group , fill = dizi2$group, x =dizi2$turkish_tvseries.runti
geom_density(alpha = 0.5) +
labs(x = "Dizi Süresi",
    y = "Yogunluk",
    title = "Dizi Sürelerinin 2000 Yili Öncesi Ve Sonrasi
    Dagilim Grafigi",
    subtitle = "Kernel Yogunluk Tahmini",
    fill = "2000 Yili") +
lims(x = c(0, 150), y = c(0, 0.04)) +
scale_fill_manual(values = met.brewer("Homer2")) +
theme_bw()
```

Dizi Sürelerinin 2000 Yili Öncesi Ve Sonrasi Dagilim Grafigi



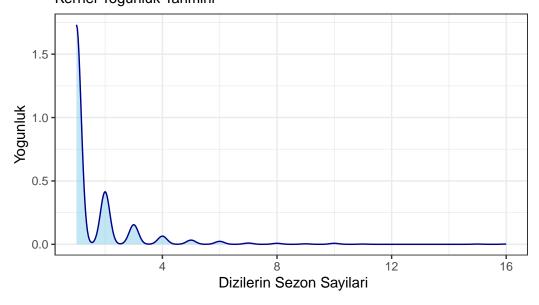


YORUM: 2000 yılından önceki yıllarda dizi süresi yoğunluğu 40 ile 60 dakika arasındadır. 2000 yılından sonraki yıllarda dizi süreleri 100 ie 150 dakika aralığında yoğunlaşmıştır.

3.3 Dizilerin Sezon Sayılarının Dağılımı Grafiği

NA değerleri çıkartılarak Dizilerin Sezon Sayıları(Number Of Season) ve Dizi Süreleri(runtimes) yeni bir csv dosyası(DataTv) haline getirilmiştir. R'a yüklenmiştir ve tanımlanmıştır. Daha sonra DataTv veri setinde bulunan Sezon sayıları(Number Of Season) değişkeni kullanılarak Dizilerin Sezon Sayılarının Dağılım Grafiği , Kernel Yoğunluk Tahmini grafiği ile gösterilmiştir.

Dizilerin Sezon Sayilarinin Dagilim Grafigi Kernel Yogunluk Tahmini



YORUM: Verilen veri setindeki Türk dizilerinin büyük bir çoğunluğunun yoğunluğu 1 ile 4. sezon arasındadır. 4 sezondan daha fazla olan dizi sayısı yoğunluğu oldukça azdır. Grafikte görüldüğü üzere dizilerin sezon yoğunluğu 1 ve 2 sezon aralığında en yüksektedir. Sezon sayısı arttıkça yoğunluk azalmaktadır.